



# Tom

## AI应用工程师

✉ tomok123@gmail.com | ✨ 英文名: Tom | 📍 支持远程/现场

### 概述

十年后端老兵，两年 AI 应用一线。写得出稳定的服务端，也调得好提示词：做过大模型网关（OpenAI 兼容、SSE 流式、多 Key 轮换）、给 IM 产品装过智能助手（单聊问答 + 群聊 @AI）、拿 RAG 把内部文档变成可问答的知识库。擅长把「跑得通的 Demo」变成「扛得住线上」的服务——超时分级、退避重试、降级兜底、Token 核算这些脏活累活都是自己一手做的。

### 技术面板

#### AI 侧

- 模型接入：OpenAI 兼容协议、Chat/Embedding 全量调用、SSE 流式解析与断连重试
- Agent：Function Calling 编排、参数校验、失败兜底；了解 Semantic Kernel 插件机制
- RAG：LangChain（Chain/Retrieval）实践 + 自研管线并用，语义切分、向量化、Top-K 召回、带出处的回答（可点回原文）
- Prompt：系统提示词版本化管理、few-shot、结构化输出约束

#### 工程侧

- 语言：Python（FastAPI）为主，Java（Spring Boot/Netty）与 C++（brpc）可上阵
- 存储/中间件：MySQL、Redis、Kafka、RocketMQ、Elasticsearch、EMQX
- 稳定性：队列+信号量并发闸门、指数退避、多模型多 Key 热备、Token 成本核算
- 底子：数据结构与算法、操作系统、计算机网络；Linux/Shell/Python 运维脚本

#### 工具链

- 日常重度使用 Claude Code / Cursor 等 AI 编程工具，有实际的 Agent 搭建经验

### 项目经验

#### 大模型统一网关

2024.06 - 2024.10 | 角色：独立交付

把多家模型 API 收拢成一套内部标准服务，业务方不改代码即可换模型。

- 接口层：OpenAI 兼容协议收口，屏蔽上游差异
- 流式层：SSE 透传、首包优先，弱网断连可续
- 稳定层：超时分级（首包/全量）、指数退避、限流自动切 Key
- 运营层：Token 计量 + 调用日志，按业务方出成本账

日均数千次调用保持零故障；流式改造把「整段干等」变成秒级首包；多模型路由叠加缓存后 Token 账单降了约三

成。

IM 智能助手

2024.11 - 2025.08 | 角色：AI 功能负责人

在即时通讯产品里落地 AI 助手，单聊直答、群聊 @触发。

- 消息链路：@识别 → 上下文组装 → 网关调用 → 流式回包，全链路自研
- 防滥用三道闸：服务层禁言/踢人、网关拦截、前端隐藏，恶意刷量有效拦截
- 提示词按场景分版本管理，人设切换不串味

AI 功能从 0 到 1 上线并成为日常入口；复用网关通道，业务侧不直接碰模型 API。

内部知识库问答

2025.09 - 2026.02 | 角色：独立交付

把规范、FAQ、运维手册做成能问答的知识库。

- 文档管线：Markdown/PDF 解析，按语义段落切分，保留标题层级
- 检索管线：Embedding + Top-K 召回，相似度阈值过滤
- 可信度：回答附来源引用，原文可核对，压幻觉
- 迭代法：badcase 归集驱动提示词与切分调参，命中率逐步爬升

上线后规范类问题基本不再靠人工答疑。

工作经历

万恒科技 | 高级后端工程师（AI 方向）

2020.03 - 2026.08（6 年）

核心系统开发与架构，2024 年起牵头大模型在 IM 与直播业务落地：AI 网关、智能助手、知识库问答全部从 0 到 1 上线；制定团队 AI 接入技术规范并推广。

技术栈：Java/Spring、Python/FastAPI、C++/brpc、MySQL、Redis、EMQX、SSE

移联科技 | 后端工程师

2014.07 - 2020.02（6 年）

企业级 SaaS 平台（200+ 企业客户）核心模块开发：表结构与索引优化、SQL 审核、分布式缓存落地、通用组件库建设。

技术栈：Spring Cloud、MyBatis、MySQL、Redis、Elasticsearch

教育

计算机科学与技术 | 本科

- 主修：数据结构与算法、计算机网络、操作系统、数据库系统
- 毕设《基于 Java 的分布式文件管理系统》获优秀毕业设计

## 证书

- CMMI Certified Associate (2016)
  - PMP 项目管理专业人士 (2018)
- 

## 联系

-  tomok123@gmail.com
- ✨ 英文名: Tom (备注: 招聘/技术交流)
- 📍 北京 • 支持远程/现场

💰 面议 | 🕒 随时到岗 | 🤝 全职