



## 个人简介

后端工程师出身的AI应用开发者，10多年Java/C++开发经验，近两年聚焦大模型应用开发：负责过LLM服务化封装（OpenAI兼容API、SSE流式输出）、IM产品内的AI助手集成、RAG文档问答应用，解决过模型服务化过程中的超时、重试、限流等性能与稳定性问题。有扎实的分布式系统设计与运维经验，熟悉常见开源中间件，能独立负责业务需求交付到线上运维的完整闭环。

## 核心优势

| 领域          | 技能描述                                                   |
|-------------|--------------------------------------------------------|
| LLM服务化      | OpenAI兼容API封装、SSE流式输出、多模型路由与降级、Token用量统计               |
| Agent/RAG应用 | Function Calling工具调用编排、群聊@AI自动应答、RAG文档切分/向量检索/引用溯源     |
| 性能与稳定性      | 超时与重试退避、并发与队列控制、结果缓存、模型降级、线上故障排查                       |
| 多语言工程       | Python (FastAPI)、Java (Spring/Netty)、C++ (brpc)，编码习惯良好 |
| 分布式系统       | MySQL/Redis/Kafka/Elasticsearch/EMQX等开源中间件的设计与运维       |
| AI工具提效      | 日常使用AI编程工具（Claude Code/Cursor等）开发与排查问题，有Agent开发实践      |

## 核心技术栈

### 大模型应用技术

| 技术分类     | 技术栈              | 熟练度    | 核心能力                           |
|----------|------------------|--------|--------------------------------|
| LLM接口    | OpenAI兼容API      | ★★★★★★ | Chat/Embedding调用、SSE流式解析、错误码处理 |
| 应用框架     | LangChain        | ★★★★★  | 使用过Chain/Retrieval组件构建RAG问答应用  |
| 应用框架     | Semantic Kernel  | ★★★★   | 了解插件与规划器机制，评估选型中对比实践           |
| Agent开发  | Function Calling | ★★★★★  | 工具调用编排、参数校验、失败兜底               |
| RAG      | 向量检索             | ★★★★★  | 文档切分、Embedding、Top-K检索、引用溯源    |
| Prompt工程 | 结构化提示词           | ★★★★★  | 系统提示词设计、few-shot、输出格式约束        |

## 推理优化与稳定性

- 流式输出: SSE首包优先，降低用户感知延迟
- 并发控制: 队列+信号量限制在途请求，防止上游过载
- 重试策略: 指数退避、超时分级（首包/全量）、幂等处理

- 降级方案: 多模型/多Key轮换, 主备通道自动切换
- 成本控制: Token统计、上下文裁剪、高频问答缓存

🔧 后端与分布式

- 编程语言: Python (FastAPI/requests) 、Java (Spring Boot/Netty) 、C++ (brpc)
- 数据库/缓存: MySQL、Redis (缓冲批量写、限流计数)
- 消息/检索: Kafka、RocketMQ、Elasticsearch
- 网络: TCP/IP、HTTP/HTTPS、WebSocket、MQTT协议实践
- 运维: Linux、Shell/Python脚本、日志采集与告警、Docker (了解K8s)
- 计算机基础: 数据结构与算法、操作系统原理、计算机网络

👛 工作经历 (10多年后端 + 2年AI应用开发)

🌟 职业亮点: 从Java/C++后端工程师起步, 2024年起转向大模型应用方向, 把分布式系统的工程经验用于LLM服务化与AI原生应用

💻 高级后端工程师 (AI应用方向) | 万恒科技

📅 任职时间: 2020.03 - 2026.08 (6年) | 🏢 职位级别: 高级 | 🎯 当前方向: LLM服务化与AI应用集成

🎯 核心使命: 负责公司核心系统的开发和架构工作, 2024年起主导大模型在IM与直播业务中的落地

🔥 主要职责

| 🎯 领域    | 📝 具体职责                  | 📈 成果              |
|---------|-------------------------|-------------------|
| 系统开发与架构 | 核心系统开发与架构设计, 解决架构关键问题   | 核心链路稳定运行, 故障率持续下降 |
| AI应用落地  | LLM服务化封装、AI助手集成、RAG应用开发 | AI功能从0到1上线并日常运行   |
| 技术规范    | 制定开发规范与算法工程技术规范, 跟踪新技术  | AI接入规范在团队内推广使用    |
| 线上运维    | 独立负责需求交付与线上服务运维         | 线上问题按规范响应与复盘      |

💻 技术栈: Java/Spring • Python/FastAPI • C++/brpc • MySQL • Redis • EMQX • SSE

🌟 后端工程师 | 移付宝

📅 任职时间: 2014.07 - 2020.02 (6年) | 🎯 业务领域: 企业级SaaS平台 | 👥 服务对象: 200+企业客户

🎯 核心使命: B端SaaS平台核心模块开发与数据库优化

🔥 主要职责与成果

- 🏗️ 系统开发: SaaS管理平台核心模块开发, 覆盖需求分析到上线交付
- 🗄️ 数据库优化: 表结构设计、索引优化、SQL审核, 查询性能明显改善
- ⚡ 缓存落地: 分布式缓存方案, 热点查询压力有效下降

-  **组件建设:** 通用组件库开发，团队协作效率提升

 **技术栈:** Spring Cloud • MyBatis • MySQL • Redis • Elasticsearch

## 核心项目经历

 **项目亮点:** 覆盖LLM应用工程化的主要环节——服务化基建、产品内AI集成、RAG应用

### LLM服务化网关（AI基建）

 **项目周期:** 2024.06 - 2024.10 |  **担任角色:** 独立负责

 **项目使命:** 将多家大模型API统一封装为公司内部标准服务，解决直接对接时的性能与稳定性问题

#### 核心模块

|  模块名称 |  功能描述 |  技术要点 |
|----------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| 统一接口                                                                                   | OpenAI兼容协议，屏蔽上游差异                                                                      | 业务方零改造切换模型                                                                             |
| SSE流式转发                                                                                | 流式输出透传，首包优先                                                                            | 首包延迟可控，断连可重试                                                                           |
| 多Key管理                                                                                 | 多Key轮换与配额管理                                                                            | 触发限流自动切换，不中断服务                                                                         |
| 稳定性                                                                                    | 超时分级、指数退避重试、降级                                                                         | 上游抖动时业务侧无感                                                                             |
| 用量统计                                                                                   | Token计量与调用日志                                                                           | 按业务方核算成本                                                                               |

#### 项目成果

-  **服务稳定:** 日常日均数千次调用，网关侧无故障运行
-  **延迟优化:** 流式输出改造后，用户感知首响应时间从整段等待变为秒级首包
-  **成本可控:** 多模型路由+缓存，Token消耗降低约30%

#### 个人贡献

-  独立完成方案设计、开发、上线与运维文档
-  沉淀AI接入技术规范，供团队业务方接入使用

### IM系统AI智能助手集成

 **项目周期:** 2024.11 - 2025.08 |  **担任角色:** AI功能负责人

 **项目使命:** 在即时通讯产品中集成AI助手，覆盖单聊问答与群聊@AI场景

#### 核心模块

|  模块名称 |  功能描述 |  技术要点 |
|------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| 流式对话                                                                                     | AI回复SSE流式输出，逐字呈现                                                                         | 打字机效果，弱网断连重试                                                                               |

| 🎯 模块名称 | 📝 功能描述                  | 📊 技术要点       |
|--------|-------------------------|--------------|
| 群聊@AI  | @AI助手自动入群应答             | 消息路由识别，上下文组装 |
| 防滥用    | 三层防护：服务层禁言/踢人+网关拦截+前端隐藏 | AI不被恶意刷量     |
| 提示词管理  | 系统提示词版本化管理              | 按场景切换人设与约束   |

### 🎉 项目成果

- 🤖 AI功能从0到1上线，成为产品日常使用的功能入口
- 🛡️ 防滥用上线后，恶意刷量调用被有效拦截
- ⚡ 复用LLM网关通道，业务侧不直接依赖模型API

### 🏆 个人贡献

- 设计AI消息链路（识别→组装上下文→调用→流式回包）
- 与产品/客户端协作定义流式协议与展示规范

## 📖 RAG文档问答应用（内部知识库）

📅 项目周期: 2025.09 - 2026.02 | 👤 担任角色: 独立负责

🎯 项目使命: 将内部文档（规范/FAQ/运维手册）做成可问答的知识库，减少重复答疑

### 🧩 核心模块

| 🎯 模块名称 | 📝 功能描述             | 📊 技术要点         |
|--------|--------------------|----------------|
| 文档处理   | Markdown/PDF解析与切分  | 按语义段落切分，保留标题层级 |
| 向量检索   | Embedding+Top-K检索  | 相似度过滤，召回上下文组装  |
| 引用溯源   | 回答附带来源段落引用         | 可核对原文，降低幻觉影响   |
| 效果迭代   | badcase收集与提示词/切分调优 | 检索命中率逐步提升      |

### 🎉 项目成果

- 📖 内部文档问答可用，常见规范类问题不再依赖人工答疑
- 🔍 回答带引用，可信度可核对

💻 核心技术栈: Python • LangChain • Embedding API • FastAPI • MySQL

## 📜 专业认证

- 📊 CMMI Certified Associate 2016 - 软件成熟度模型认证
- 👤 PMP项目管理专业人士认证 2018 - 项目管理专业能力

## 综合评价

 **核心价值:** 分布式系统的工程严谨性 + 大模型应用的落地经验，能把AI能力稳定地装进业务系统

### 核心竞争力

-  **AI应用工程化:** 模型服务化、流式输出、稳定性保障的完整实践
-  **分布式背景:** 10多年后端与中间件经验，理解线上服务的运维工具和规范
-  **基础扎实:** 计算机原理、网络、数据结构功底，源码级排查开源框架问题
-  **AI工具熟练:** 日常开发重度使用AI工具，关注AIGC/LLM新技术动态并动手验证
-  **协作与学习:** 较强沟通协作能力，愿意接触新事物，不局限于原有技术栈

### 职业方向

- 深耕LLM应用架构与Agent工程化，参与大模型应用的规模化建设
- 在算法工程与业务系统之间做好工程侧的桥梁

## 联系方式

### 直接联系

-  **邮箱:** u30337@gmail.com
-  **微信:** Bevan（备注：招聘/技术交流）
-  **地点:** 北京 · 可远程/曼谷居家办公

### 期望

-  **期望薪资:** 面议
-  **到岗时间:** 随时到岗
-  **合作方式:** 全职（远程或曼谷到岗均可）