



个人简介

后端工程师出身的AI应用开发者，10多年Java/C++开发经验，近两年聚焦**大模型应用开发**：负责过LLM服务化封装（OpenAI兼容API、SSE流式输出）、IM产品内的AI助手集成、RAG文档问答应用，解决过模型服务化过程中的超时、重试、限流等性能与稳定性问题。有扎实的**分布式系统设计与运维经验**，熟悉常见开源中间件，能独立负责业务需求交付到线上运维的完整闭环。

核心优势

领域	技能描述
LLM服务化	OpenAI兼容API封装、SSE流式输出、多模型路由与降级、Token用量统计
Agent/RAG应用	Function Calling工具调用编排、群聊@AI自动应答、RAG文档切分/向量检索/引用溯源
性能与稳定性	超时与重试退避、并发与队列控制、结果缓存、模型降级、线上故障排查
多语言工程	Python（FastAPI）、Java（Spring/Netty）、C++（brpc），编码习惯良好
分布式系统	MySQL/Redis/Kafka/Elasticsearch/EMQX等开源中间件的设计与运维
AI工具提效	日常使用AI编程工具（Claude Code/Cursor等）开发与排查问题，有Agent开发实践

核心技术栈

大模型应用技术

技术分类	技术栈	熟练度	核心能力
LLM接口	OpenAI兼容API	★★★★★★	Chat/Embedding调用、SSE流式解析、错误码处理
应用框架	LangChain	★★★★★	使用过Chain/Retrieval组件构建RAG问答应用
应用框架	Semantic Kernel	★★★★	了解插件与规划器机制，评估选型中对比实践
Agent开发	Function Calling	★★★★★	工具调用编排、参数校验、失败兜底
RAG	向量检索	★★★★★	文档切分、Embedding、Top-K检索、引用溯源
Prompt工程	结构化提示词	★★★★★	系统提示词设计、few-shot、输出格式约束

推理优化与稳定性

- 流式输出**: SSE首包优先，降低用户感知延迟
- 并发控制**: 队列+信号量限制在途请求，防止上游过载
- 重试策略**: 指数退避、超时分级（首包/全量）、幂等处理

- 降级方案: 多模型/多Key轮换, 主备通道自动切换
- 成本控制: Token统计、上下文裁剪、高频问答缓存

🔧 后端与分布式

- 编程语言: Python (FastAPI/requests) 、Java (Spring Boot/Netty) 、C++ (brpc)
- 数据库/缓存: MySQL、Redis (缓冲批量写、限流计数)
- 消息/检索: Kafka、RocketMQ、Elasticsearch
- 网络: TCP/IP、HTTP/HTTPS、WebSocket、MQTT协议实践
- 运维: Linux、Shell/Python脚本、日志采集与告警、Docker (了解K8s)
- 计算机基础: 数据结构与算法、操作系统原理、计算机网络

👛 工作经历 (10多年后端 + 2年AI应用开发)

🌟 职业亮点: 从Java/C++后端工程师起步, 2024年起转向大模型应用方向, 把分布式系统的工程经验用于LLM服务化与AI原生应用

💻 高级后端工程师 (AI应用方向) | 万恒科技

📅 任职时间: 2020.03 - 2026.08 (6年) | 🏢 职位级别: 高级 | 🎯 当前方向: LLM服务化与AI应用集成

🎯 核心使命: 负责公司核心系统的开发和架构工作, 2024年起主导大模型在IM与直播业务中的落地

🔥 主要职责

🎯 领域	📝 具体职责	📈 成果
系统开发与架构	核心系统开发与架构设计, 解决架构关键问题	核心链路稳定运行, 故障率持续下降
AI应用落地	LLM服务化封装、AI助手集成、RAG应用开发	AI功能从0到1上线并日常运行
技术规范	制定开发规范与算法工程技术规范, 跟踪新技术	AI接入规范在团队内推广使用
线上运维	独立负责需求交付与线上服务运维	线上问题按规范响应与复盘

💻 技术栈: Java/Spring • Python/FastAPI • C++/brpc • MySQL • Redis • EMQX • SSE

🌟 后端工程师 | 移付宝

📅 任职时间: 2014.07 - 2020.02 (6年) | 🎯 业务领域: 企业级SaaS平台 | 👥 服务对象: 200+企业客户

🎯 核心使命: B端SaaS平台核心模块开发与数据库优化

🔥 主要职责与成果

- 🏗️ 系统开发: SaaS管理平台核心模块开发, 覆盖需求分析到上线交付
- 🗄️ 数据库优化: 表结构设计、索引优化、SQL审核, 查询性能明显改善
- ⚡ 缓存落地: 分布式缓存方案, 热点查询压力有效下降

-  **组件建设:** 通用组件库开发，团队协作效率提升

 **技术栈:** Spring Cloud • MyBatis • MySQL • Redis • Elasticsearch

核心项目经历

 **项目亮点:** 覆盖LLM应用工程化的主要环节——服务化基建、产品内AI集成、RAG应用

LLM服务化网关（AI基建）

 **项目周期:** 2024.06 - 2024.10 |  **担任角色:** 独立负责

 **项目使命:** 将多家大模型API统一封装为公司内部标准服务，解决直接对接时的性能与稳定性问题

核心模块

 模块名称	 功能描述	 技术要点
统一接口	OpenAI兼容协议，屏蔽上游差异	业务方零改造切换模型
SSE流式转发	流式输出透传，首包优先	首包延迟可控，断连可重试
多Key管理	多Key轮换与配额管理	触发限流自动切换，不中断服务
稳定性	超时分级、指数退避重试、降级	上游抖动时业务侧无感
用量统计	Token计量与调用日志	按业务方核算成本

项目成果

-  **服务稳定:** 日常日均数千次调用，网关侧无故障运行
-  **延迟优化:** 流式输出改造后，用户感知首响应时间从整段等待变为秒级首包
-  **成本可控:** 多模型路由+缓存，Token消耗降低约30%

个人贡献

-  独立完成方案设计、开发、上线与运维文档
-  沉淀AI接入技术规范，供团队业务方接入使用

IM系统AI智能助手集成

 **项目周期:** 2024.11 - 2025.08 |  **担任角色:** AI功能负责人

 **项目使命:** 在即时通讯产品中集成AI助手，覆盖单聊问答与群聊@AI场景

核心模块

 模块名称	 功能描述	 技术要点
流式对话	AI回复SSE流式输出，逐字呈现	打字机效果，弱网断连重试

🎯 模块名称	📝 功能描述	📊 技术要点
群聊@AI	@AI助手自动入群应答	消息路由识别，上下文组装
防滥用	三层防护：服务层禁言/踢人+网关拦截+前端隐藏	AI不被恶意刷量
提示词管理	系统提示词版本化管理	按场景切换人设与约束

🎉 项目成果

- 🤖 AI功能从0到1上线，成为产品日常使用的功能入口
- 🛡️ 防滥用上线后，恶意刷量调用被有效拦截
- ⚡ 复用LLM网关通道，业务侧不直接依赖模型API

🏆 个人贡献

- 设计AI消息链路（识别→组装上下文→调用→流式回包）
- 与产品/客户端协作定义流式协议与展示规范

📖 RAG文档问答应用（内部知识库）

📅 项目周期: 2025.09 - 2026.02 | 👤 担任角色: 独立负责

🎯 **项目使命:** 将内部文档（规范/FAQ/运维手册）做成可问答的知识库，减少重复答疑

🧩 核心模块

🎯 模块名称	📝 功能描述	📊 技术要点
文档处理	Markdown/PDF解析与切分	按语义段落切分，保留标题层级
向量检索	Embedding+Top-K检索	相似度过滤，召回上下文组装
引用溯源	回答附带来源段落引用	可核对原文，降低幻觉影响
效果迭代	badcase收集与提示词/切分调优	检索命中率逐步提升

🎉 项目成果

- 📖 内部文档问答可用，常见规范类问题不再依赖人工答疑
- 🔍 回答带引用，可信度可核对

💻 **核心技术栈:** Python • LangChain • Embedding API • FastAPI • MySQL

📜 专业认证

- 🗝️ **Oracle OCP数据库管理员认证** 2013 - 数据库专业技能认证

💡 综合评价

🎯 **核心价值:** 分布式系统的工程严谨性 + 大模型应用的落地经验，能把AI能力稳定地装进业务系统

🎯 核心竞争力

- 🏠 **AI应用工程化**: 模型服务化、流式输出、稳定性保障的完整实践
- 🏗️ **分布式背景**: 10多年后端与中间件经验，理解线上服务的运维工具和规范
- 🧠 **基础扎实**: 计算机原理、网络、数据结构功底，源码级排查开源框架问题
- 🛠️ **AI工具熟练**: 日常开发重度使用AI工具，关注AIGC/LLM新技术动态并动手验证
- 🤝 **协作与学习**: 较强沟通协作能力，愿意接触新事物，不局限于原有技术栈

🚀 职业方向

- 深耕LLM应用架构与Agent工程化，参与大模型应用的规模化建设
 - 在算法工程与业务系统之间做好工程侧的桥梁
-

📞 联系方式

✉️ 直接联系

- ✉️ **邮箱**: u30337@gmail.com
- 📱 **微信**: Bevan（备注：招聘/技术交流）
- 📍 **地点**: 北京 • 可远程/曼谷居家办公

💰 期望

- 💼 **期望薪资**: 面议
- 🕒 **到岗时间**: 随时到岗
- 🌟 **合作方式**: 全职（远程或曼谷到岗均可）