



高级AI应用工程师

✉ smith778899@gmail.com | ✨ 英文名: Smith | 📍 北京 • 可远程/现场办公

👤 个人简介

后端工程师出身的AI应用开发者，10多年Java/C++开发经验，近两年聚焦大模型应用开发：负责过LLM服务化封装（OpenAI兼容API、SSE流式输出）、IM产品内的AI助手集成、RAG文档问答应用，解决过模型服务化过程中的超时、重试、限流等性能与稳定性问题。有扎实的分布式系统设计与运维经验，熟悉常见开源中间件，能独立负责业务需求交付到线上运维的完整闭环。

🎯 核心优势

领域	技能描述
LLM服务化	OpenAI兼容API封装、SSE流式输出、多模型路由与降级、Token用量统计
Agent/RAG应用	Function Calling工具调用编排、群聊@AI自动应答、RAG文档切分/向量检索/引用溯源
性能与稳定性	超时与重试退避、并发与队列控制、结果缓存、模型降级、线上故障排查
多语言工程	Python (FastAPI)、Java (Spring/Netty)、C++ (brpc)，编码习惯良好
分布式系统	MySQL/Redis/Kafka/Elasticsearch/EMQX等开源中间件的设计与运维
AI工具提效	日常使用AI编程工具（Claude Code/Cursor等）开发与排查问题，有Agent开发实践

🔧 专业技能

🤖 大模型应用

- LLM接口：OpenAI兼容API，Chat/Embedding调用、SSE流式解析、错误码处理（熟练）
- 应用框架：LangChain，使用过Chain/Retrieval组件构建RAG问答应用；Semantic Kernel，了解插件与规划器机制，评估选型中对比实践
- Agent开发：Function Calling工具调用编排、参数校验、失败兜底
- RAG：文档切分、Embedding、Top-K检索、引用溯源
- Prompt工程：系统提示词设计、few-shot、输出格式约束

⚡ 推理优化与稳定性

- 流式输出：SSE首包优先，降低用户感知延迟
- 并发控制：队列+信号量限制在途请求，防止上游过载
- 重试策略：指数退避、超时分级（首包/全量）、幂等处理
- 降级方案：多模型/多Key轮换，主备通道自动切换
- 成本控制：Token统计、上下文裁剪、高频问答缓存

🔧 后端与分布式

- 编程语言：Python (FastAPI/requests)、Java (Spring Boot/Netty)、C++ (brpc)

- 数据库/缓存：MySQL、Redis（缓冲批量写、限流计数）
- 消息/检索：Kafka、RocketMQ、Elasticsearch
- 网络：TCP/IP、HTTP/HTTPS、WebSocket、MQTT协议实践
- 运维：Linux、Shell/Python脚本、日志采集与告警、Docker（了解K8s）
- 计算机基础：数据结构与算法、操作系统原理、计算机网络

工作经历（10多年后端 + 2年AI应用开发）

职业亮点：从Java/C++后端工程师起步，2024年起转向大模型应用方向，把分布式系统的工程经验用于LLM服务化与AI原生应用。

万恒科技 | 高级后端工程师（AI应用方向）

2020.03 - 2026.08（6年） | 职位级别：高级 | 当前方向：LLM服务化与AI应用集成
负责公司核心系统的开发和架构工作，2024年起主导大模型在IM与直播业务中的落地。

领域	具体职责	成果
系统开发与架构	核心系统开发与架构设计，解决架构关键问题	核心链路稳定运行，故障率持续下降
AI应用落地	LLM服务化封装、AI助手集成、RAG应用开发	AI功能从0到1上线并日常运行
技术规范	制定开发规范与算法工程技术规范，跟踪新技术	AI接入规范在团队内推广使用
线上运维	独立负责需求交付与线上服务运维	线上问题按规范响应与复盘

技术栈：Java/Spring、Python/FastAPI、C++/brpc、MySQL、Redis、EMQX、SSE

移联科技 | 后端工程师

2014.07 - 2020.02（6年） | 业务领域：企业级SaaS平台 | 服务对象：200+企业客户
B端SaaS平台核心模块开发与数据库优化。

- 系统开发：SaaS管理平台核心模块开发，覆盖需求分析到上线交付
- 数据库优化：表结构设计、索引优化、SQL审核，查询性能明显改善
- 缓存落地：分布式缓存方案，热点查询压力有效下降
- 组件建设：通用组件库开发，团队协作效率提升

技术栈：Spring Cloud、MyBatis、MySQL、Redis、Elasticsearch

项目经历

项目亮点：覆盖LLM应用工程化的主要环节——服务化基建、产品内AI集成、RAG应用。

LLM服务化网关（AI基建）

2024.06 - 2024.10 | 担任角色：独立负责

将多家大模型API统一封装为公司内部标准服务，解决直接对接时的性能与稳定性问题。

模块	功能描述	技术要点
统一接口	OpenAI兼容协议，屏蔽上游差异	业务方零改造切换模型
SSE流式转发	流式输出透传，首包优先	首包延迟可控，断连可重试
多Key管理	多Key轮换与配额管理	触发限流自动切换，不中断服务
稳定性	超时分级、指数退避重试、降级	上游抖动时业务侧无感
用量统计	Token计量与调用日志	按业务方核算成本

🎉 项目成果：

- 服务稳定：日常日均数千次调用，网关侧无故障运行
- 延迟优化：流式输出改造后，用户感知首响应时间从整段等待变为秒级首包
- 成本可控：多模型路由+缓存，Token消耗降低约30%

🏆 个人贡献：独立完成方案设计、开发、上线与运维文档；沉淀AI接入技术规范，供团队业务方接入使用。

💬 IM系统AI智能助手集成

2024.11 - 2025.08 | 担任角色：AI功能负责人

在即时通讯产品中集成AI助手，覆盖单聊问答与群聊@AI场景。

模块	功能描述	技术要点
流式对话	AI回复SSE流式输出，逐字呈现	打字机效果，弱网断连重试
群聊@AI	@AI助手自动入群应答	消息路由识别，上下文组装
防滥用	三层防护：服务层禁言/踢人+网关拦截+前端隐藏	AI不被恶意刷量
提示词管理	系统提示词版本化管理	按场景切换人设与约束

🎉 项目成果：

- AI功能从0到1上线，成为产品日常使用的功能入口
- 防滥用上线后，恶意刷量调用被有效拦截
- 复用LLM网关通道，业务侧不直接依赖模型API

🏆 个人贡献：设计AI消息链路（识别→组装上下文→调用→流式回包）；与产品/客户端协作定义流式协议与展示规范。

📖 RAG文档问答应用（内部知识库）

2025.09 - 2026.02 | 担任角色：独立负责

将内部文档（规范/FAQ/运维手册）做成可问答的知识库，减少重复答疑。

模块	功能描述	技术要点
文档处理	Markdown/PDF解析与切分	按语义段落切分，保留标题层级
向量检索	Embedding+Top-K检索	相似度过滤，召回上下文组装
引用溯源	回答附带来源段落引用	可核对原文，降低幻觉影响
效果迭代	badcase收集与提示词/切分调优	检索命中率逐步提升

🎉 项目成果：

- 内部文档问答可用，常见规范类问题不再依赖人工答疑
- 回答带引用，可信度可核对

核心技术栈：Python、LangChain、Embedding API、FastAPI、MySQL

📜 专业认证

- 📊 CMMI Certified Associate (2016) - 软件成熟度模型认证
- 👤 PMP项目管理专业人士认证 (2018) - 项目管理专业能力

💡 综合评价

核心价值：分布式系统的工程严谨性 + 大模型应用的落地经验，能把AI能力稳定地装进业务系统。

🎯 核心竞争力

- AI应用工程化：模型服务化、流式输出、稳定性保障的完整实践
- 分布式背景：10多年后端与中间件经验，理解线上服务的运维工具和规范
- 基础扎实：计算机原理、网络、数据结构功底，源码级排查开源框架问题
- AI工具熟练：日常开发重度使用AI工具，关注AIGC/LLM新技术动态并动手验证
- 协作与学习：较强沟通协作能力，愿意接触新事物，不局限于原有技术栈

🚀 职业方向

- 深耕LLM应用架构与Agent工程化，参与大模型应用的规模化建设
- 在算法工程与业务系统之间做好工程侧的桥梁

📞 联系方式

- 📧 邮箱：smith778899@gmail.com
- ✨ 英文名：Smith（备注：招聘/技术交流）
- 📍 地点：北京 • 可远程/现场办公

💰 期望薪资：面议 | 🕒 到岗时间：随时到岗 | 🤝 合作方式：全职（远程或现场到岗均可）